Rapport technique

Ce que coûte vraiment la quantification d'un LLM sur un ordinateur portable

Vitesse, mémoire, précision et énergie de modèles locaux sur Apple Silicon

Anthony Vang
Cycle ingénieur Data & IA, ESILV | novembre 2026

Résumé. La quantification des poids est la méthode courante pour faire tourner un grand modèle de langage sur du matériel grand public. On la présente souvent comme presque gratuite en qualité et nettement plus économe en énergie. Nous avons voulu vérifier ces deux affirmations sur un MacBook Air sans ventilateur (puce Apple M5, 16 Go), avec vingt configurations : deux modèles Qwen2.5 (1,5 et 3 milliards de paramètres), sept niveaux de quantification sous llama.cpp, de F16 à Q2_K, et trois niveaux sous MLX. Pour chacune, nous mesurons le débit de génération, la mémoire, l'énergie par token lue sur les compteurs matériels, la précision sur 300 problèmes GSM8K, la perplexité et la divergence KL par rapport au modèle F16, ainsi que le comportement sous charge prolongée. Jusqu'à environ 4 bits par poids, la précision ne change pas de façon mesurable (84,7 % en Q4_K_M contre 85,0 % en F16 pour le modèle 3B) et le débit est multiplié par 2,5. L'énergie par token ne baisse en revanche que de 28 %, car la puissance appelée augmente avec la vitesse. Sous 4 bits, le petit modèle se dégrade bien plus vite que le grand : à mémoire égale, un modèle plus gros et plus compressé est préférable.

1 Introduction

Exécuter un modèle de langage en local garde les données sur la machine, supprime la latence réseau et le coût par requête. La contrainte principale est la mémoire : en précision 16 bits, un modèle de 3 milliards de paramètres occupe environ 6 Go. La quantification réduit la précision des poids à 8, 4 bits ou moins, et la taille du modèle diminue d'autant.

Deux idées accompagnent généralement ce choix. La première veut que la quantification en 4 bits ne coûte presque rien en qualité ; la seconde, qu'elle économise de l'énergie à peu près en proportion du gain de vitesse. Ce rapport les met à l'épreuve sur une seule machine, de bout en bout, en mesurant la précision sur une tâche réelle plutôt que la seule perplexité, l'énergie à partir des compteurs matériels, et la vitesse sur la durée, là où un portable sans ventilateur finit par ralentir.

2 Dispositif expérimental

Matériel. MacBook Air équipé d'une puce Apple M5 et de 16 Go de mémoire unifiée, refroidissement passif, sur secteur.

Modèles et moteurs. Qwen2.5-1.5B-Instruct et Qwen2.5-3B-Instruct, au format GGUF officiel pour llama.cpp (F16, Q8_0, Q6_K, Q5_K_M, Q4_K_M, Q3_K_M, Q2_K) et dans les conversions communautaires pour MLX (bf16, 8 bits, 4 bits). Le niveau de compression est exprimé en *bits par poids effectifs*, soit la taille du fichier multipliée par 8 et divisée par le nombre de paramètres. Les noms des formats K-quant sous-estiment en effet la taille réelle : un Q4_K_M représente environ

4,9 à 5,0 bits par poids.

Outil de mesure. Toutes les mesures sont faites avec `jpt`, un outil en ligne de commande écrit pour cette étude avec la seule bibliothèque standard de Python. Il pilote les serveurs d'inférence, enregistre chaque mesure dans une base SQLite avec son contexte matériel et logiciel, et régénère les tableaux et les figures à partir de cette base. Les campagnes peuvent reprendre après interruption, et le code est couvert par des tests unitaires exécutés en intégration continue.

3 Méthode

Débit. Trois requêtes couvrent des régimes différents : une explication longue et une tâche de génération de code (256 tokens produits chacune), puis le résumé d'un texte long (64 tokens). Après une requête de chauffe non comptée, chaque requête est répétée trois fois en décodage glouton, avec une longueur de sortie fixe. Nous retenons la médiane et son coefficient de variation. Une pause de 10 s sépare les essais, et chaque configuration ne démarre qu'une fois la puce revenue à un état thermique nominal. Le cache de prompt est neutralisé afin que la phase de lecture du prompt soit payée à chaque essai.

Énergie. Les canaux *Energy Model* de la bibliothèque IOReport d'Apple exposent des compteurs d'énergie cumulés pour le CPU, le GPU, le moteur neuronal et la DRAM. L'énergie d'une requête est la différence entre deux relevés pris juste avant et juste après, ce qui évite toute erreur d'échantillonnage. La consommation au repos est mesurée avant chaque configuration, une fois l'activité de fond retombée.

Mémoire. Avec Metal, les poids résident dans une mémoire GPU verrouillée qui n'est pas attribuée au processus du serveur. La mémoire maximale est donc mesurée comme l'augmentation de la mémoire verrouillée du système pendant la requête, à laquelle s'ajoute l'empreinte du processus.

Qualité. Pour GSM8K, nous utilisons les 300 premiers problèmes du jeu de test, posés via le modèle de conversation de chaque moteur et notés par correspondance exacte sur le résultat final, avec un intervalle de Wilson à 95 % (environ ± 4 à 5 points). La perplexité et la divergence KL sont calculées par `llama-perplexity` sur 40 segments de 512 tokens de WikiText-2. La divergence KL compare la distribution du token suivant de chaque modèle quantifié à celle du modèle F16 ; nous indiquons aussi la part des positions où les deux modèles placent le même token en tête.

Sélection. Une configuration appartient à la frontière de Pareto si aucune autre n'est au moins aussi bonne en précision, en débit et en énergie par token, tout en étant strictement meilleure sur l'un de ces critères.

4 Résultats

Le tableau 1 rassemble les vingt configurations.

4.1 Jusqu'à 4 bits, la précision est préservée

Sur 300 problèmes GSM8K, le modèle 3B obtient 85,0 % en F16 et entre 84,3 et 84,7 % de Q8_0 à Q4_K_M. Le modèle 1,5B reste entre 73,0 et 75,0 % sur la même plage. Ces écarts sont nettement inférieurs aux intervalles de confiance. La dérive existe pourtant à l'échelle du token : en Q4_K_M, le modèle choisit le même token suivant que F16 dans 91 % des cas, pour une divergence KL

Table 1. Résultats principaux. Débit et énergie sont des médianes sur neuf requêtes. ⋆ : configuration sur la frontière de Pareto (précision, débit, énergie). La perplexité et l'accord avec F16 ne sont mesurés que pour llama.cpp.

Modèle	Format	Bits / poids	Débit (tok/s)	Énergie (J/tok)	Mémoire (Go)	GSM8K (%)	Perplexité	Même token que F16 (%)
1,5B	F16	16,00	37,4	0,237	3,37	74,7	9,17	100,0
	Q8_0	8,50	64,7	0,158	1,73	73,0	9,17	98,7
	Q6_K⋆	6,56	72,9	0,170	1,91	75,0	9,19	95,9
	Q5_K_M	5,76	72,5	0,201	1,48	73,7	9,23	94,3
	Q4_K_M⋆	5,00	83,1	0,137	1,70	73,3	9,57	90,6
	Q3_K_M[a]	4,13	80,7	0,165	1,57	43,3	10,28	82,9
	Q2_K[a]	3,36	120,2	0,144	1,11	16,7	15,21	66,8
	MLX bf16[b]	16	40,3	0,194	7,55	72,7	–	–
	MLX 8 bits[b]	8	68,8	0,191	5,19	72,7	–	–
	MLX 4 bits[b⋆]	4	122,3	0,109	3,79	66,7	–	–
3B	F16	16,00	21,2	0,366	6,34	85,0	8,07	100,0
	Q8_0	8,50	36,5	0,287	3,68	84,3	8,07	98,8
	Q6_K	6,56	44,5	0,343	2,99	84,3	8,10	96,9
	Q5_K_M	5,73	49,2	0,367	2,70	84,3	8,16	95,0
	Q4_K_M⋆	**4,94**	**53,3**	**0,262**	**2,47**	**84,7**	**8,32**	**91,3**
	Q3_K_M	4,05	56,1	0,293	2,15	79,7	8,80	85,4
	Q2_K	3,23	64,2	0,247	1,83	60,3	12,49	70,1
	MLX bf16[b⋆]	16	20,7	0,355	13,26	86,3	–	–
	MLX 8 bits[b⋆]	8	37,7	0,245	7,98	85,0	–	–
	MLX 4 bits[b⋆]	4	56,4	0,189	5,35	79,7	–	–

[a] Débit instable (coefficient de variation supérieur à 10 %), valeur indicative. [b] Mémoire probablement surestimée, la mesure incluant le cache de tampons de MLX ; bits par poids nominaux.

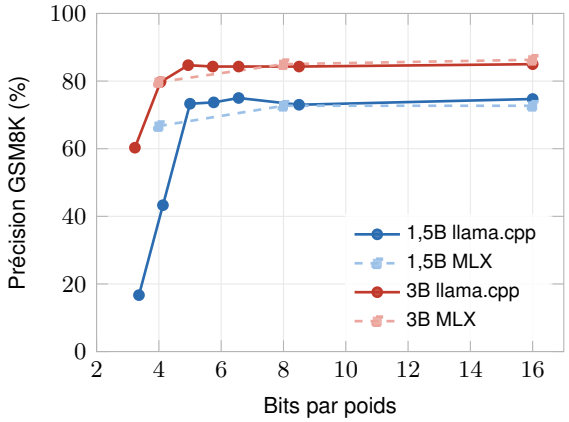
moyenne de 0,03 (figure 1). Sous 4 bits, la dérive s'accélère et la précision suit : 79,7 % puis 60,3 % pour le modèle 3B en Q3_K_M et Q2_K.

4.2 Un modèle plus grand et plus compressé l'emporte

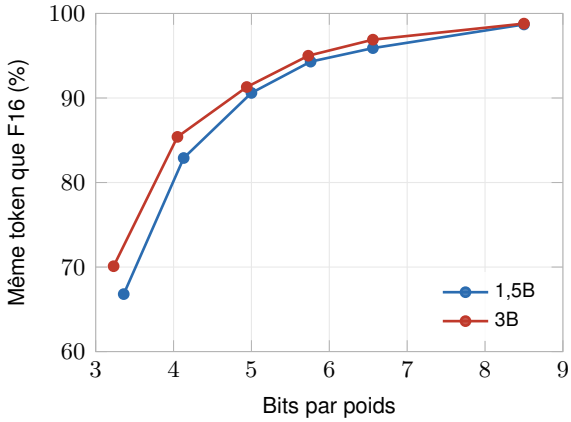
Le petit modèle s'effondre bien plus tôt : en Q3_K_M, le 1,5B tombe à 43,3 % sur GSM8K quand le 3B se maintient à 79,7 %. Le 3B en Q3_K_M (2,2 Go) dépasse ainsi le 1,5B en pleine précision (3,4 Go, 74,7 %) avec 35 % de mémoire en moins, et il reste plus proche de son propre modèle F16 à tous les niveaux de quantification. Pour un budget mémoire donné, il vaut mieux choisir le plus gros modèle qui tient une fois quantifié.

4.3 La vitesse suit la compression, l'énergie beaucoup moins

Du F16 au Q4_K_M, le débit du modèle 3B passe de 21,2 à 53,3 tokens par seconde, soit un facteur 2,5, alors que l'énergie par token ne baisse que de 0,366 à 0,262 J, soit 28 %. La génération est limitée par la bande passante mémoire : chaque poids est relu une fois par token produit, et des poids plus légers se relisent plus vite. Mais la puce travaille davantage et sa puissance moyenne passe de 7,8 à 13,4 W. L'énergie par token étant le rapport de la puissance au débit, l'essentiel du gain de vitesse est absorbé par ce surcroît de puissance (figure 2).

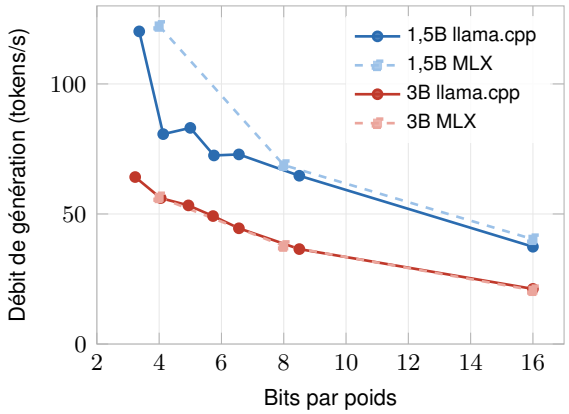


(a) Précision sur 300 problèmes GSM8K.

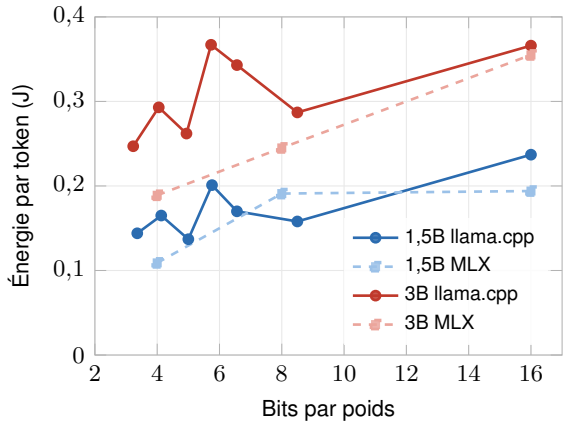


(b) Accord avec le modèle F16 (llama.cpp).

Figure 1. Qualité en fonction du nombre de bits par poids.



(a) Débit de génération.



(b) Énergie de la puce par token généré.

Figure 2. Débit et énergie en fonction du nombre de bits par poids.

4.4 Le moteur compte autant que le format

En 4 bits sur le modèle 3B, MLX consomme 28 % d'énergie en moins par token que llama.cpp (0,189 contre 0,262 J) pour un débit comparable. Sa méthode de quantification, plus simple, coûte en revanche 5 points sur GSM8K (79,7 contre 84,7 %), et 7 points sur le modèle 1,5B. Les formats K-quant de llama.cpp réservent davantage de précision aux tenseurs les plus sensibles, ce qui préserve la qualité à nombre de bits égal. Les deux moteurs ont des configurations sur la frontière de Pareto (figure 3).

4.5 Un test de quelques secondes surestime la vitesse réelle

Après 15 minutes de génération continue, la puce sans ventilateur réduit sa fréquence : le Q4_K_M passe de 54 à 45 tokens par seconde (−16 %), le F16 perd 10 %. La configuration la plus rapide appelle le plus de puissance, chauffe davantage et se trouve donc la plus bridée. Un banc d'essai de quelques secondes surestime la vitesse qu'un utilisateur constatera en usage prolongé.

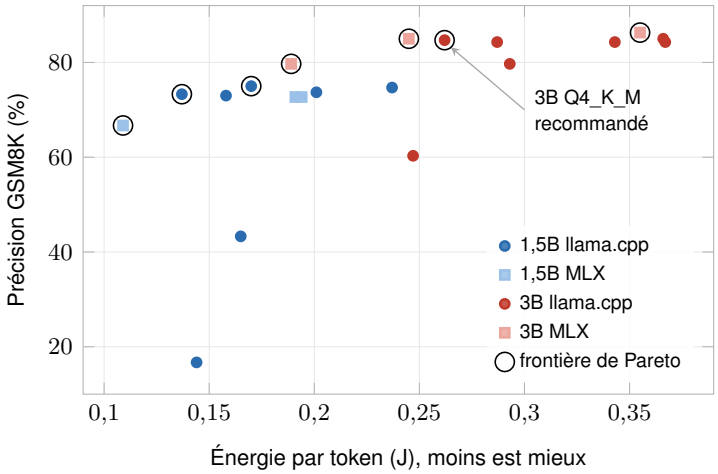


Figure 3. Précision et énergie par token des vingt configurations. Les points cerclés sont sur la frontière de Pareto, calculée sur la précision, le débit et l'énergie.

5 Recommandation

Sur cette machine, la configuration à retenir est **Qwen2.5-3B en Q4_K_M avec llama.cpp** : une précision égale à celle du F16 aux marges d'erreur près (84,7 contre 85,0 %), un débit multiplié par 2,5, 2,5 Go de mémoire, et une place sur la frontière de Pareto. Lorsque l'énergie compte davantage que quelques points de précision, MLX en 4 bits est l'option la plus sobre.

6 Limites et suite

L'étude porte sur une seule machine, une seule famille de modèles et deux petites tailles ; ses conclusions ne se transposent pas directement à des modèles de 7 milliards de paramètres ou plus, ni à du matériel refroidi activement. L'énergie mesurée est celle de toute la puce et non du seul modèle : la soustraction de la consommation au repos et l'usage de médianes réduisent le bruit de fond sans l'éliminer. Deux configurations (1,5B en Q3_K_M et Q2_K) restent instables en débit, et la mémoire mesurée pour MLX est probablement surestimée.

Les prochaines étapes sont l'ajout d'un modèle de 7 à 8 milliards de paramètres et d'une seconde famille de modèles, l'évaluation sur l'ensemble du jeu de test GSM8K (1 319 problèmes), et la séparation de l'énergie entre lecture du prompt et génération sur des contextes longs.

Reproductibilité

Le code, les données brutes, le tableau complet des résultats et la méthodologie détaillée sont disponibles dans le dépôt `joules-per-token`. Chaque tableau et chaque figure de ce rapport se régénère à partir de la base de mesures avec la commande `jpt report`.